

Credit Card Fraud Detection

Contesto di Business, Modellazione, Interpretabilità e Analisi degli Errori

1. Contesto di business e obiettivo del progetto

Le frodi su carte di credito rappresentano un problema critico per banche ed emittenti, sia in termini di **perdite economiche dirette** sia di **impatto sulla customer experience**.

Un sistema di fraud detection efficace deve poter intercettare il maggior numero possibile di transazioni fraudolente senza però generare un numero eccessivo di blocchi su transazioni legittime.

Il problema è caratterizzato da due elementi chiave:


1. **Forte sbilanciamento delle classi:** le transazioni fraudolente rappresentano una frazione estremamente ridotta del totale, come avviene tipicamente in scenari reali.
2. **Asimmetria dei costi di errore:**
 - una frode non intercettata (*false negative*) comporta una perdita economica diretta;
 - il blocco errato di una transazione legittima (*false positive*) genera costi operativi e impatta negativamente sull'esperienza del cliente.

Per questo motivo, l'obiettivo del progetto **non è massimizzare l'accuratezza**, ma **costruire modelli che consentano di controllare il trade-off tra intercettazione delle frodi e falsi allarmi**, ottimizzando la soglia decisionale in funzione di differenti **scenari di costo**.

Stima dei costi di business

In assenza di informazioni dirette sui costi di chargeback e gestione delle frodi, si utilizza l'importo delle transazioni fraudolente come proxy del danno economico diretto associato a una frode non intercettata (False Negative). In particolare, vengono analizzati la **media**, la **mediana** e i **percentili** della distribuzione degli importi fraudolenti, al fine di ottenere una stima robusta e interpretabile del costo.

	amt
count	9651.000000
mean	530.661412
std	391.028873
min	1.060000
50%	390.000000
90%	1024.610000
95%	1084.090000
99%	1175.850000
max	1376.040000



L'analisi della distribuzione degli importi delle transazioni fraudolente mostra una forte asimmetria, con una coda destra pronunciata. La mediana dell'importo fraudolento è pari a circa 390 €, mentre la media è pari a circa 531 €, indicando la presenza di frodi di importo elevato che influenzano la media.

Per evitare che il costo associato a una frode non intercettata sia eccessivamente influenzato da outlier, si utilizza la **mediana dell'importo fraudolento** come stima principale del costo di un falso negativo. La media e i percentili superiori verranno invece utilizzati per un'analisi di sensibilità sui costi.

Sensitivity analysis


Scenario	Cost_FN (€)	Motivazione
Conservativo	300	Sotto la mediana
Base	390	Mediana
Medio-alto	530	Media
Alto	1000	~90° percentile

2. Dataset e analisi esplorativa

Il dataset utilizzato è il *Credit Card Transactions Fraud Detection Dataset* disponibile su Kaggle, composto da circa 1.5 milioni di transazioni simulate ma realistiche, distribuite nel periodo 2019–2020. Ogni transazione include informazioni su importo, tempo, cliente, merchant, categoria, localizzazione geografica ed etichetta di frode.

L'analisi esplorativa iniziale ha cercato di rispondere a domande puntali per poter poi pilotare le scelte finali di feature engineering.



Distribuzione delle classi : Quanto è sbilanciato il dataset?



Il dataset presenta un forte sbilanciamento delle classi: le transazioni fraudolente rappresentano meno dell'1% del totale (**Legit** 1.842.743 - 99.48% | **Fraud** 9.651 - 0.52%)





Questo rende il problema particolarmente complesso e richiede l'utilizzo di metriche e strategie di modellazione adeguate al contesto di imbalanced learning (es. Recall, Precision, F1-score).

Distribuzione dell'importo: Quanto varia e target medio, può essere discriminante?



La distribuzione degli importi mostra una forte asimmetria e una coda lunga. Sebbene le transazioni fraudolente presentino in media importi più elevati, esiste una significativa sovrapposizione con le transazioni legittime, indicando che l'importo da solo non è sufficiente per discriminare le frodi. Per aiutare il modello a migliorare la capacità di generalizzare si è deciso di utilizzare la forma logaritmica dell'importo.

Pattern Temporali: le frodi avvengono più spesso in certe ore/giorni?




L'analisi temporale evidenzia pattern ricorrenti nelle transazioni fraudolente, con fasce orarie, giorni della settimana e mesi caratterizzati da un rischio maggiore. Questo giustifica l'introduzione di feature temporali nel modello.


Sebbene il dataset copra un periodo di più anni, durante le operazioni di feature engineering, non è stata introdotta una variabile esplicita "anno". Questa scelta è motivata dalla volontà di progettare una pipeline scalabile nel tempo, in cui l'aggiunta di nuovi dati che coprano più anni, non richieda modifiche strutturali al feature space.


Analisi per Categorie e Merchant: esistono categorie e merchant più a rischio?

È stata calcolata la % di frodi su tutte le transazioni di una certa categoria o commerciante e visualizzati graficamente.



Quello che segue è un barplot con tutti i commercianti posti in ordine secondo l'indicatore di rischio calcolato.





Indicatore aggregato di rischio (tutti i merchant): 3.506

Indicatore aggregato di rischio - top 20% merchant: 1.946


Indicatore aggregato di rischio - restante 80% merchant: 1.560

L'analisi per categoria e merchant evidenzia che entrambe le variabili sono fortemente informative ai fini della rilevazione delle frodi. In particolare, alcune categorie (come `shopping_net`, `misc_net` e `grocery_pos`) mostrano tassi di frode significativamente più elevati rispetto alla media del dataset, suggerendo una maggiore esposizione al rischio in specifici contesti di spesa.


Analogamente, il rischio di frode associato ai merchant presenta una distribuzione fortemente eterogenea, con una chiara concentrazione del rischio: una quota relativamente ridotta di merchant (circa il 20%) concentra una parte rilevante del rischio aggregato, indicando un effetto di tipo Pareto.


Tuttavia, anche per i merchant più esposti, il tasso di frode rimane ampiamente inferiore al 3%, evidenziando come nessuna singola categoria o merchant possa essere considerato deterministico. Questo suggerisce che tali variabili debbano essere utilizzate, data inoltre l'alta cardinalità, come segnali probabilistici all'interno di un modello di apprendimento supervisionato, piuttosto che come regole rigide di blocco, e integrate con ulteriori informazioni temporali, geografiche e comportamentali.

Analisi geografica cliente-merchant: più distante vuol dire anche più rischioso?



Nell'esercizio viene effettuato il calcolo della distanza in km utilizzando la formula di **Haversine**.





L'analisi della distanza geografica tra cliente e merchant mostra che le distribuzioni delle transazioni legittime e fraudolente risultano ampiamente sovrapposte. In particolare, entrambe le classi presentano una distribuzione unimodale con un picco in corrispondenza di distanze intermedie, suggerendo che la distanza assoluta non costituisca un fattore discriminante sufficiente per l'individuazione delle frodi.

L'analisi congiunta con l'importo della transazione evidenzia inoltre che le frodi tendono a concentrarsi su importi mediamente più elevati, indipendentemente dalla distanza cliente-merchant. Questo indica che la **distanza geografica fornisce un segnale informativo debole** se considerata isolatamente, ma può contribuire all'identificazione di comportamenti anomali quando combinata con altre variabili, quali l'importo, il contesto temporale e il comportamento storico del cliente.

Nel complesso, i risultati suggeriscono che la distanza cliente-merchant debba essere interpretata come una feature di supporto, utile all'interno di un modello multivariato, piuttosto che come una regola deterministica di classificazione.

Queste osservazioni hanno guidato direttamente le scelte di feature engineering e di modellazione.

Il dataset è stato trattato come serie temporale, mantenendo un ordinamento cronologico rigoroso e adottando uno split temporale in train, validation e test, evitando qualsiasi mescolamento casuale che avrebbe introdotto leakage.

3. Preprocessing e feature engineering

Il feature engineering è stato progettato con tre obiettivi principali:

1. **Catturare pattern comportamentali** di clienti e merchant.
2. **Incorporare la dimensione temporale** in modo coerente con un contesto di inferenza online.
3. **Evitare leakage informativo**, mantenendo una separazione rigorosa tra passato e futuro.

Inoltre, le varie funzioni create per le operazioni necessarie sono state incapsulate in pipeline riutilizzabili e serializzate, in modo da garantire coerenza tra training, validation e serving.

3.1 Feature temporali

Sono state introdotte feature temporali derivate dal timestamp della transazione, tra cui:

- ora del giorno,
- giorno della settimana,
- mese,
- indicatori binari (notte, weekend),
- trasformazioni cicliche (seno/coseno).

Motivazione: i comportamenti fraudolenti mostrano spesso periodicità e pattern orari non lineari; le trasformazioni cicliche permettono ai modelli di catturare queste relazioni senza introdurre discontinuità artificiali.

Nota sulla rappresentazione temporale e multicollinearità

Nel processo di modellazione sono state incluse sia feature temporali discrete (ora, giorno della settimana, mese) sia le corrispondenti rappresentazioni cicliche (seno/coseno).

Per i modelli tree-based (Random Forest e XGBoost), tale ridondanza non rappresenta un problema, in quanto questi algoritmi non sono sensibili alla multicollinearità e selezionano autonomamente le feature più informative.

Per la Logistic Regression, che è sensibile alla collinearità tra feature, questa scelta è stata mitigata tramite l'utilizzo di **regolarizzazione**, che riduce l'instabilità dei coefficienti e consente al modello di gestire feature ridondanti. Inoltre, la Logistic Regression viene utilizzata principalmente come **baseline di riferimento**, più che per un'interpretazione puntuale dei coefficienti.

In un contesto di produzione o di interpretazione causale, la rappresentazione temporale verrebbe ulteriormente semplificata selezionando una sola codifica per ciascuna variabile temporale.

3.2 Feature geografiche

È stata calcolata la distanza geografica cliente–merchant tramite formula di Haversine.

Motivazione: transazioni effettuate a distanze insolite rispetto alla storia del cliente sono un forte indicatore di frode, specialmente in combinazione con altri segnali.

3.3 Feature storiche cliente e merchant

Sono state costruite feature storiche incrementalmente, tra cui:

- numero di transazioni precedenti,
- numero di frodi precedenti,
- tassi di frode smoothed (con prior bayesiano),
- indicatori di “nuovo merchant per cliente”.

Sono stati scelti dei tassi di frode smoothed, così da non avere tassi eccessivamente penalizzati e quindi fuorvianti, derivanti ad esempio dal caso in cui vi siano poche apparizioni di un dato merchant con la maggior parte di transazioni fraudolente.

Scelta metodologica (Train-Val → Test)

Durante la fase di test, **tutte le feature storiche supervisionate sono state congelate allo stato di fine validation.**

Perché?

- aggiornare tali feature richiederebbe l'uso dell'etichetta di frode,
- introdurrebbe leakage non realistico,
- altererebbe la distribuzione delle probabilità rispetto a quella su cui la soglia è stata ottimizzata.

[Importante] si è in seguito valutato di risolvere il problema dell'etichetta mancante, utilizzando man mano le predizioni del modello come riferimento, seppur imperfetto; teoricamente questo dovrebbe riuscire a mantenere la distribuzione coerente evitando problemi come l'effetto *data drift*, causato, in questo esempio, dall'invecchiamento degli ultimi stati (calcolati alla fine del train) rispetto alle transazioni più recenti su cui viene effettuata la predizione.

Con il congelamento degli stati, durante gli esperimenti in test si è osservato che l'aggiornamento dinamico di alcune feature, in particolare solo quelle che non dipendono da `is_fraud` (es. delta dall'ultima transazione o nuovo merchant), modificava significativamente la calibrazione delle probabilità, peggiorando metriche come PR-AUC pur non dipendendo direttamente dalla soglia. Per garantire una valutazione imparziale e coerente, si è quindi scelto di mantenere lo stato congelato.

4. Modellazione

Sono stati addestrati e confrontati tre modelli supervisionati:

- **Logistic Regression** (baseline interpretabile) → fornisce un riferimento interpretabile e robusto;
- **Random Forest** → consente di modellare interazioni non lineari;
- **XGBoost** → è particolarmente efficace su dati tabellari anche sbilanciati.

Lo **sbilanciamento** è stato gestito tramite:

- **class_weight** per Logistic Regression e Random Forest,
- **scale_pos_weight** per XGBoost.
- **ottimizzazione della soglia decisionale** basata su una **funzione di costo**.

Leakage

Durante la progettazione si è cercato quanto più possibile di evitare il fenomeno di data leakage attraverso:

- calcolo incrementale delle feature storiche (utilizzando esclusivamente informazioni precedenti alla transazione);
- congelamento degli stati tra validation e test (in questo caso il modello risulta praticamente offline, il che si è notato sviluppare un problema di degrado delle prestazioni; uno scenario ottimale sarebbe quello in cui le feature storiche vengano man mano calcolate utilizzando quante più informazioni possibili, precedenti alla transazione oggetto di inferenza, modello online);
- utilizzo coerente delle soglie (calcolate in fase di addestramento senza essere influenzate da informazioni future in fase di test).

Gli aggiornamenti dinamici di solo alcune feature, es. delta dall'ultima transazione, nuovo merchant, sono stati testati ma scartati per garantire coerenza distributiva, infatti ciò andava a peggiorare di molto le prestazioni di tutti i modelli.

Drift

Il progetto simula uno scenario offline, ma in produzione sarebbero necessari:

- monitoraggio delle distribuzioni delle feature;
- controllo del drift sulle probabilità;
- retraining periodico.

5. Metriche e ottimizzazione della soglia

Data la natura del problema, l'**accuracy** non è stata considerata informativa. Le metriche principali sono state:

- **Recall su frodi** (riduzione dei falsi negativi)
→ risponde alla domanda: *su tutte le transazioni realmente fraudolente, quale percentuale il modello riesce a individuare correttamente?*
- **Precision su frodi** (controllo dei falsi positivi)
→ risponde alla domanda: *tra tutte le transazioni che il modello classifica come fraudolente, quale percentuale è effettivamente fraudolenta?*
- **F1-score su frodi**
→ rappresenta la media armonica tra precision e recall, fornendo una misura sintetica del compromesso tra intercettazione delle frodi e controllo dei falsi allarmi. È particolarmente utile quando si desidera un equilibrio tra le due metriche in contesti sbilanciati.

- **PR-AUC (Area Under the Precision-Recall Curve)**

→ misura la capacità del modello di mantenere un buon livello di precision e recall al variare della soglia di classificazione.

- **Costo atteso** (calcolato tramite una funzione di costo asimmetrica)

→ integra esplicitamente l'impatto economico degli errori di classificazione, assegnando un costo maggiore ai falsi negativi rispetto ai falsi positivi. Questa metrica consente di valutare il modello non solo in termini statistici, ma anche in ottica di ottimizzazione del rischio e del valore di business.

La soglia decisionale non è stata quindi fissata a 0.5, ma ottimizzata in validation secondo diversi scenari di costo associati ai falsi negativi (Conservative, Baseline, Medium-high, High).

Le soglie ottimali sono state salvate insieme ai modelli e riutilizzate in fase di test, simulando uno scenario operativo realistico. Tuttavia, per mantenere livelli di performance dei modelli accettabili dal business, sarebbe opportuno aggiornare periodicamente tali soglie attraverso successivi addestramenti effettuati su nuovi batch di transazioni eseguite.

5.1 Analisi dei risultati

Confronto dei modelli

- **Logistic Regression:** modello stabile e interpretabile, ma limitato nella capacità di catturare interazioni non lineari.
- **Random Forest:** buon compromesso recall/precision, ma con maggiore instabilità sulle probabilità.
- **XGBoost:** miglior compromesso complessivo, con PR-AUC elevata, miglior controllo dei FN e probabilità ben calibrate.

XGBoost è risultato il modello finale scelto per la pipeline di inferenza.

Di seguito vengono riportati i risultati dei modelli in fase di validation e test, rispetto le varie fasce di costo:

Logistic Regression - Val Analysis

	thresholds	costs	recall	precision	f1_score	pr_auc
Conservative	0.8866	184850	0.5885	0.1934	0.2911	0.4138
Baseline	0.8423	229980	0.6461	0.1229	0.2065	0.4138
Medium-high	0.8423	291860	0.6461	0.1229	0.2065	0.4138
High	0.7241	470550	0.7454	0.0575	0.1068	0.4138

Logistic Regression - Test Analysis

	thresholds	costs	recall	precision	f1_score	pr_auc
Conservative	0.8866	591300	0.0825	0.6629	0.1468	0.2372
Baseline	0.8423	742180	0.1152	0.5576	0.1909	0.2372
Medium-high	0.8423	1007900	0.1152	0.5576	0.1909	0.2372
High	0.7241	1645590	0.2359	0.4343	0.3057	0.2372

Random Forest - Val Analysis

	thresholds	costs	recall	precision	f1_score	pr_auc
Conservative	0.4778	37630	0.9408	0.4323	0.5924	0.8713
Baseline	0.4680	44190	0.9424	0.4222	0.5831	0.8713
Medium-high	0.3203	51900	0.9640	0.3003	0.4580	0.8713
High	0.3203	73050	0.9640	0.3003	0.4580	0.8713

Random Forest - Test Analysis

	thresholds	costs	recall	precision	f1_score	pr_auc
Conservative	0.4778	185120	0.7361	0.5076	0.6008	0.7128
Baseline	0.4680	234280	0.7389	0.4995	0.5961	0.7128
Medium-high	0.3203	292750	0.7837	0.2641	0.3951	0.7128
High	0.3203	510830	0.7837	0.2641	0.3951	0.7128

XGB - Val Analysis

	thresholds	costs	recall	precision	f1_score	pr_auc
Conservative	0.2316	13360	0.9816	0.6549	0.7856	0.9746
Baseline	0.2316	15430	0.9816	0.6549	0.7856	0.9746
Medium-high	0.2119	18570	0.9824	0.6397	0.7749	0.9746
High	0.2119	28910	0.9824	0.6397	0.7749	0.9746

XGB - Test Analysis


	thresholds	costs	recall	precision	f1_score	pr_auc
Conservative	0.2316	123650	0.8219	0.6608	0.7326	0.8580
Baseline	0.2316	158030	0.8219	0.6608	0.7326	0.8580
Medium-high	0.2119	208930	0.8247	0.6470	0.7251	0.8580
High	0.2119	385650	0.8247	0.6470	0.7251	0.8580

6. Interpretabilità e analisi errori

6.1 Interpretabilità globale


- I coefficienti della Logistic Regression mostrano che **importo, orario notturno e tassi storici di frode** sono i segnali più forti, come anche particolari stati e categorie di spesa.
- L'analisi SHAP su XGBoost conferma questi pattern, mostrando effetti coerenti ma non lineari.

Questo rafforza la fiducia nel modello, poiché le feature più influenti sono allineate con l'intuizione di dominio.



Top coefficienti della Logistic Regression, ordinati per valore assoluto, che mostrano l'effetto delle feature lineari sul log-odds di frode.

SHAP summary plot per XGBoost



Importanza globale delle feature: Il grafico mostra l'impatto medio assoluto (mean |SHAP value|) di ciascuna feature sulla predizione della probabilità di frode


Distribuzione degli effetti delle feature sulla probabilità di frode: Il grafico evidenzia la direzione e la variabilità dell'impatto di ciascuna feature, complementando l'analisi di importanza globale mostrata nel SHAP summary plot (bar).

6.2 Analisi degli errori

L'analisi di false negative e false positive è stata condotta sia a livello aggregato sia tramite spiegazioni locali SHAP.


- I **false negative** tendono a essere transazioni fraudolente con profilo “quasi normale”, spesso caratterizzate da **storico cliente pulito** e dove **segnali di rischio vengono compensati da feature rassicuranti**.
- I **false positive** sono spesso legati a **importi elevati o combinazioni rare di categoria/orario**.

SHAP Waterfall – esempio False Negative



Spiegazione locale (SHAP waterfall) di una frode non intercettata: come i contributi delle feature spingono la stima del modello verso una previsione legittima.

SHAP Waterfall – esempio False Positive



Spiegazione locale (SHAP waterfall) di una transazione legittima classificata come frode: contributi delle feature che hanno spinto la decisione del modello.

Sovrapposizione degli errori tra modelli

- FN overlap (LR&RF): 547
- FN overlap (LR&XGB): 382
- FN overlap (RF&XGB): 362
- FP overlap (LR&RF): 10
- FP overlap (LR&XGB): 19
- FP overlap (RF&XGB): 385

L'analisi di sovrapposizione degli errori suggerisce che modelli diversi intercettano frodi differenti, aprendo a possibili strategie di **ensemble**.

7. Pipeline di inferenza e serving

È stata implementata una pipeline completa di inferenza che:

- carica preprocessore e modello;
- calcola la probabilità di frode;
- applica la soglia selezionata;
- restituisce una decisione operativa (blocco / approvazione).

È disponibile sia una versione con etichette note (per valutazione ex-post dei costi reali), sia una versione realistica senza etichette, pensata per l'utilizzo in produzione.

8. Limitazioni e sviluppi futuri

Il progetto presenta alcune limitazioni:

- assenza di tecniche avanzate per il bilanciamento delle classi (SMOTE o oversampling guidato);
- assenza di modellazione esplicita delle sequenze temporali;
- possibile drift nel tempo dei pattern di frode.

Sviluppi futuri includono:

- tecniche di **upsampling** avanzato come suggerito in letteratura (da SMOTE a tecniche più avanzate come GAN-Transformer);
- modelli **sequence-based** o **graph-based**: modelli che tengono conto rispettivamente della dimensione temporale degli eventi o delle relazioni strutturali tra entità, al fine di catturare dipendenze complesse nei dati (es. LSTM, Transformer; Graph Neural Network);
- **sistemi di monitoring per concept drift e retraining automatico**: sistemi che monitorano nel tempo i cambiamenti nelle distribuzioni dei dati o nelle predizioni del modello e attivano procedure automatiche di riaddestramento quando tali cambiamenti diventano significativi.